UNIVERSIDAD
DE SANTIAGO
DE CHILE

Departamento de Ingeniería Industrial

Estadística Aplicada

2do. Semestre 2026

PROYECTO INTEGRADOR: REGRESIÓN CASO I

Predicción de la Generación Eléctrica de una Turbina de Gas Mediante Regresión Lineal

Docente
Luis Rojo Gonzalez
Francisco Gomez Fernandez

Ayudante
Benjamin Quezada Lopez
Tomas Painepi Rojas
Amaro Castro
Isidora Inzunza Sepulveda

Integrantes
Maria Ignacia Cordova
Vicente Urra Cisternas
Martín Peñailillo Salazar
Millaray Rodríguez Oses

SANTIAGO-CHILE
2026

Resumen Ejecutivo

En este trabajo se evalúa cómo estimar la producción de energía por hora (TEY, en MWh) de una turbina de gas utilizando 8 variables de su entorno y de su operación interna. Se analizaron 36.733 registros horarios entre 2011 y 2015. Para evitar engañar al modelo con datos del mismo periodo, se entrenó con los años 2011 a 2014 y se probó en condiciones no vistas del año 2015. El modelo de regresión Lasso ofreció el mejor desempeño, reduciendo el error de estimación ($RMSE$) de 16,19 MWh (del modelo base por promedio) a sólo 1,62 MWh en el año 2015, lo que representa una mejora del 89,96%. El modelo se recomienda como una herramienta de apoyo para el monitoreo en tiempo real de la planta.

1. Problemas, datos y disponibilidad temporal

El objetivo es estimar el rendimiento energético horario (TEY) de una turbina de gas que opera a plena carga. Cada fila del dataset representa un resumen horario de mediciones continuas. La aplicación práctica de este modelo busca apoyar al equipo de operaciones en la planta termoeléctrica, permitiendo comparar en tiempo real si la energía que realmente está entregando la turbina coincide con la potencia teórica calculada según el estado del equipo.

Los datos provienen del repositorio UCI (Gas Turbine CO and NOx Emission Data Set) y abarcan 36.733 mediciones realizadas entre 2011 y 2015. Se utilizan 8 variables predictoras: tres ambientales (AT,AP,AH) y cinco operacionales internas (AFDP,GTEP,TIT,TAT,CDP). No existen datos faltantes en el conjunto original.

Puesto que las variables operacionales se miden dentro de la misma hora en que se genera la energía, el modelo debe entenderse como un sistema de monitoreo en tiempo real y no como un pronóstico anticipado a una hora.

2. Relaciones e inferencia

Al analizar las relaciones individuales mediante una regresión lineal simple sobre los datos de entrenamiento (2011–2014), se observa que la temperatura ambiente (AT) tiene un impacto negativo directo en la producción: por cada 1ºC que aumenta la temperatura del aire, la energía generada (TEY) disminuye en promedio 0,37 MWh. Esto concuerda con la física del proceso, ya que el aire caliente es menos denso y reduce la eficiencia del compresor.

Por otro lado, se detectó una severa redundancia de información (multicolinealidad) entre las variables internas de la turbina, destacando la presión del compresor (CDP, VIF = 225,1) y la presión de escape (GTEP, VIF = 121,9). Al estar tan correlacionadas entre sí, la regresión lineal tradicional (OLS) se vuelve inestable, lo que justifica probar modelos con regularización (como Ridge y Lasso) que filtren o reduzcan el peso de las variables duplicadas.

3. Validación y preparación

Para evaluar el modelo de forma realista, se reservó el año 2015 completo (7.384 registros) exclusivamente como conjunto de prueba final. Para elegir el mejor algoritmo durante la etapa de desarrollo, se utilizaron 3 bloques de validación temporal acumulativa (entrenar 2011 para validar 2012; entrenar 2011–2012 para validar 2013; y entrenar 2011–2013 para validar el inicio de 2014). Un tramo final de 2014 (1.790 filas) se separó para calibrar los márgenes de incertidumbre.

Todas las transformaciones de datos (como la estandarización) se calcularon únicamente dentro de los datos de entrenamiento de cada bloque, asegurando que ninguna información del futuro filtra hacia la validación o prueba.

4. Modelos

Se compararon diez alternativas de modelamiento frente a un modelo base ingenuo (Baseline, que predice la media histórica):

1. Regresión Lineal Clásica (OLS).
2. Regresiones con penalización: Ridge, Lasso y Elastic Net.
3. Modelos flexibles no lineales: GAM y Árbol de Regresión.
4. Ensembles: Random Forest, XGBoost y un modelo promedio de varios algoritmos.

El criterio principal de selección fue obtener el menor error cuadrático medio (RMSE) promediado en los tres bloques de validación. El modelo Lasso (λ= 0,10) resultó seleccionado por presentar el error medio más bajo (1,02 MWh) y una alta estabilidad entre periodos.

5. Comparación, test y subgrupos

Modelo	Familia	RMSE ± DE	MAE	R^2	vs baseline
Baseline	Referencia	14,772 ± 2,235	10,696	-0,019	0,0 %
OLS	Lineal	1,772 ± 1,625	1,528	0,969	86,6 %
Ridge	Regular.	1,258 ± 0,498	1,035	0,990	91,0 %
Lasso	**Regular.**	**1,021 ± 0,123**	**0,813**	**0,995**	**92,9 %**
Elastic Net	Regular.	1,055 ± 0,205	0,843	0,994	92,6 %
GAM	Flexible	1,595 ± 1,227	1,380	0,978	88,1 %
Árbol	Árbol	2,551 ± 0,632	1,806	0,963	82,0 %
Random Forest	Ensamble	1,290 ± 0,470	0,971	0,990	90,8 %

XGBoost	Ensamble	1,266 ± 0,528	0,996	0,990	90,9 %
Averaging	Ensamble	1,254 ± 0,624	0,991	0,989	90,9 %

En la prueba final del año 2015, el modelo Lasso logró reducir el error promedio de 16,19 MWh (Baseline) a 1,62 MWh, explicando el 98,99% de la variabilidad del rendimiento energético.

Al evaluar el comportamiento en días calurosos (subgrupo con temperatura ambiental superior a 23,66 ºC, el modelo mantuvo su precisión con un $RMSE$ de $1,55\ MWh$, demostrando solidez en condiciones térmicas exigentes. No obstante, el rango de predicción esperado al 90% solo cubrió el 81,42% de los casos reales, lo que advierte que los márgenes de error reales son ligeramente más amplios de lo estimado.

Tabla 2. Evaluación única en 2015 (7.384 registros), luego de fijar el sistema ganador.

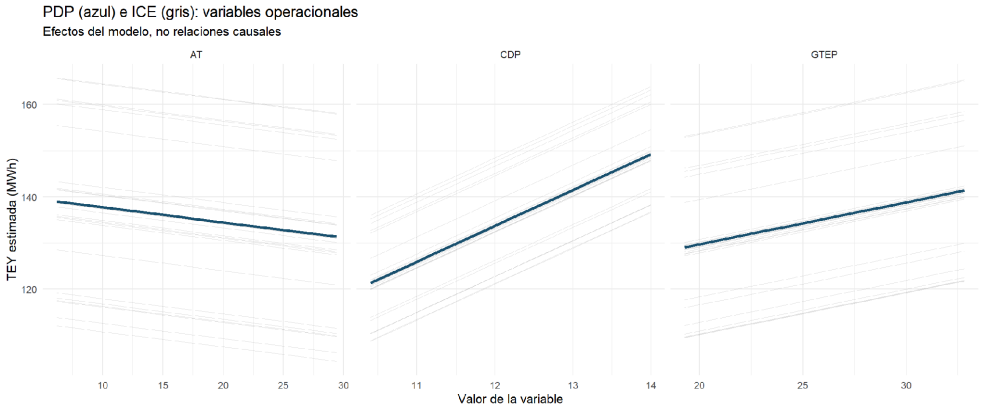
Sistema	RMSE (MWh)	MAE (MWh)	R²	Mejora RMSE
Baseline	16,1896	12,9453	−0,0014	—
Lasso	1,6249	1,1971	0,9899	89,96 %

6. Interpretación, límites y recomendación

El modelo Lasso simplificó la ecuación conservando únicamente cinco variables clave:

- Aumentan la energía: Presión del compresor (CDP, +6,83), Presión de escape (GTEP, +1,14) y Temperatura de entrada (TIT, +0,20).
- Disminuyen la energía: Temperatura ambiente (AT, -0,34) y Presión ambiente (AP, -0,01).
- Variables omitidas por el modelo: Humedad (AH), filtro de aire (AFDP) y temperatura post-turbina (TAT) recibieron coeficientes cero.

La variable con mayor impacto práctico en las predicciones fue la presión del compresor (CDP).



Límites del modelo: Los errores del modelo no son totalmente independientes a lo largo del tiempo (tienen una alta autocorrelación serial), lo que significa que si el modelo se equivoca en

una hora, tiende a mantener esa desviación en las horas siguientes. Además, el modelo no debe extrapolarse a otras plantas o turbinas distintas sin previa revalidación.

Recomendación operacional: Se recomienda implementar el modelo Lasso como una herramienta de alertas preventivas en la planta. Si la diferencia entre la energía real medida y la estimada por el modelo supera los 3 MWh de forma sostenida, el equipo técnico debe revisar si existe descalibración en sensores o pérdida de eficiencia en el equipo. No se debe utilizar este modelo para hacer pronósticos comerciales a futuro ni para asumir relaciones causales puras.

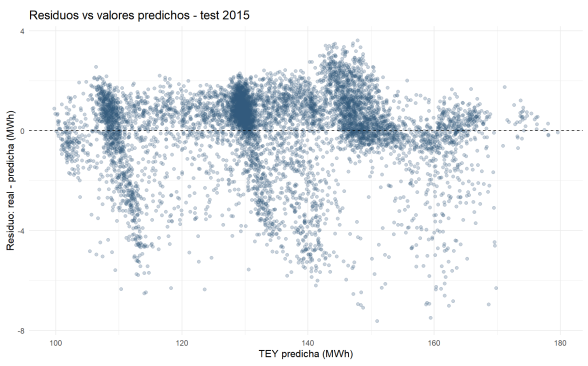
7. Comparación y resultado final

La evaluación por bloques temporales demostró que el modelo Lasso superó a alternativas más complejas como Random Forest o XGBoost. En la prueba independiente con los datos no vistos del año 2015, el modelo confirmó su efectividad al reducir el error de predicción (RMSE) en un 89,96% respecto al modelo base promedio.

No obstante, se observó un incremento en el error promedio, pasando de 1,02 MWh en la etapa de validación a 1,62 MWh en la prueba final de 2015. Asimismo, los rangos de incertidumbre proyectados no alcanzaron el nivel de cobertura esperado.

Recomendaciones Operacionales para la Planta Uso en Monitoreo en Tiempo Real:

- Implementar el modelo Lasso exclusivamente como una referencia de contraste para comparar la energía real generada frente a la estimación teórica del equipo.
- Disponibilidad de Sensores: Utilizar la herramienta únicamente cuando las 8 variables predictoras estén midiendo correctamente y sin fallas de transmisión en ese instante.
- Seguimiento de Desviaciones: Llevar un registro continuo del error horario para detectar posibles cambios en el comportamiento del equipo o descalibración de los sensores.
- Recalibración Periódica: Reservar nuevos bloques de datos operativos para reentrenar el modelo y ajustar los rangos de incertidumbre antes de tomar decisiones críticas en la planta.
- Restricciones de Uso: No utilizar este modelo como un pronóstico comercial anticipado a futuro ni para interpretar relaciones de causalidad directa.



Referencias

UCI Machine Learning Repository (2019). Gas Turbine CO and NOx Emission Data Set. DOI: 10.24432/C5WC95. https://archive.ics.uci.edu/dataset/551/gas+turbine+co+and+nox+emission+data+set (licencia CC BY 4.0).

Rojo-González, L. (2026). Estadística Aplicada: Slides y material docente. Departamento de Ingeniería Industrial, Universidad de Santiago de Chile.

Universidad de Santiago de Chile (2026). Rúbrica de evaluación: Proyecto Integrador, Regresión, Caso 1; Template_Informe.pdf (documentación entregada por el curso)

A. Diccionario de variables

Variable	Papel	Unidad	Ventana y disponibilidad
AT	Predictora	°C	Mismo período; sin anticipación confirmada
AP	Predictora	mbar	Mismo período; sin anticipación confirmada
AH	Predictora	%	Mismo período; sin anticipación confirmada
AFDP	Predictora	mbar	Mismo período; sin anticipación confirmada
GTEP	Predictora	mbar	Mismo período; sin anticipación confirmada
TIT	Predictora	°C	Mismo período; sin anticipación confirmada
TAT	Predictora	°C	Mismo período; sin anticipación confirmada
CDP	Predictora	mbar	Mismo período; sin anticipación confirmada
TEY	Respuesta	MWh	Producción energética del período horario
CO	Excluida	mg/m³	Emisión del mismo período; no usada
NOx	Excluida	mg/m³	Emisión del mismo período; no usada

B. Reproducibilidad y declaración de IA

Se ejecutó script regresion OPTIMIZADO.R en RStudio usando los cinco CSV originales gt_2011.csv a gt_2015.csv.
Semilla 2026; R4.6.1 (Windows11), paquetes y versiones registrados en 23_versiones_R_y_paquetes.txt. La carpeta resultados_optimizados contiene métricas por

fold (11_resultados_por_fold.csv), validación (12_TABLA_OFICIAL_VALIDACION_TEMPORAL.csv), test (14_TEST_FINAL_2015.csv), subgrupo (15_TEST_SUBGRUPO_ALTA_TEMPERATURA.csv), intervalos (16_INTERVALOS_PREDICCION.csv), diagnósticos y modelo final. Para reproducir: descomprimir, verificar la carpeta dataset, abrir el script y pulsar Source; revisar mensaje FIN y las salidas. Está pendiente comprobar una segunda ejecución desde una sesión limpia independiente.

Declaración de IA (editar según uso real del equipo): se utilizó ChatGPT (OpenAI) como apoyo para revisión metodológica, reorganización del código y redacción de esta maqueta. Los integrantes deben verificar todos los cálculos, referencias y decisiones.

UNIVERSIDAD
DE SANTIAGO
DE CHILE

Departamento de Ingeniería Industrial

Estadística Aplicada

2do. Semestre 2026