INGENIERÍA INDUSTRIAL

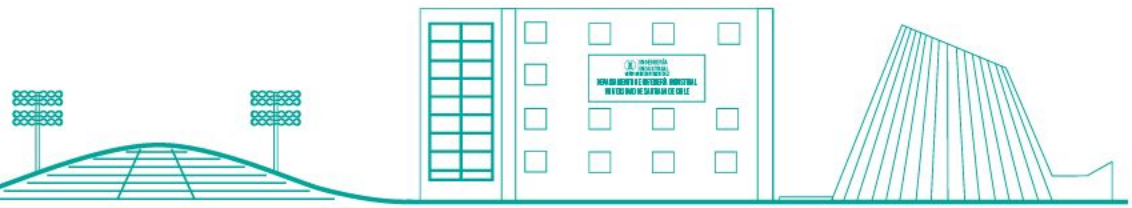
UNIVERSIDAD DE SANTIAGO DE CHILE

PROYECTO INTEGRADOR REGRESIÓN

Predicción de la Generación Eléctrica de una Turbina de Gas Mediante Regresión Lineal

Maria Ignacia Cordova
Martín Peñailillo Salazar
Millaray Rodríguez Oses
Vicente Urra Cisternas

Estadística Aplicada · Ingeniería Industrial



1. Problema y decisión industrial

Problema y Usuario

- Central termoeléctrica: la producción medida puede diferir de la generación esperada para sus condiciones de operación.

- Usuario: equipo de operaciones y mantenimiento.

- Decisión: investigar desviaciones persistentes y revisar sensores o funcionamiento del equipo.

- Costo potencial: falsas alarmas, diagnósticos tardíos y decisiones operacionales poco eficientes.

Definiciones Estadísticas

- Unidad de análisis: un registro horario de la turbina.

- Variable respuesta (Y): TEY, generación reportada en MWh por hora de registro.

- Predicción contemporánea: las ocho X se miden en la misma hora que TEY.

- Población: condiciones comparables a las observadas en esta turbina a plena carga.

2. Datos y Variables de estudio

Fuente

•UCI: Gas Turbine CO and NOx Emission Data Set (Turquía).

• 36.733 registros horarios: período 2011–2015.

• Respuesta continua: TEY (unidad reportada en el informe: MWh).

• La base original declara cero valores faltantes; se verifica nuevamente después de importarla.

• CO y NOx se conservan en la base, pero no son X del modelo principal, Se excluyen CO y NOx por ser emisiones contaminantes resultantes (efectos) y no variables de operación.

Variables

AMBIENTALES
•AT: temperatura ambiente (°C).
• AP: presión (mbar).
•AH: humedad relativa (%).

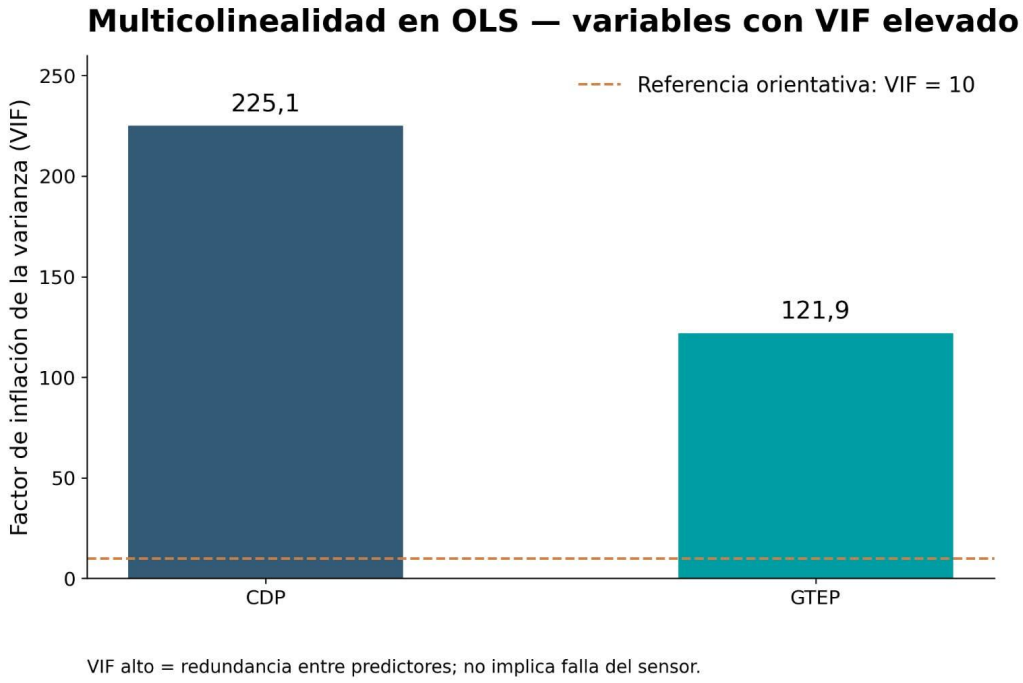
OPERACIONALES
•AFDP: diferencial de presión del filtro de aire.
•GTEP: presión de escape de la turbina.
•TIT: temperatura de entrada.
•TAT: temperatura posterior.
•CDP: presión de descarga del compresor.

3. Exploración y multicolinealidad

Hallazgos

- No se reportan NA en la base original; verificar después de importar.
- Atípicos: revisar contexto antes de excluir datos válidos.
- Relación simple AT–TEY: pendiente reportada ≈ −0,37 por cada +1 °C (asociación,no causalidad).
- IC convencional del 95% para βAT: [−0,3740; −0,3693] MWh/°C
- La dependencia temporal obliga a revisar residuos y usar validación cronológica.
- Los VIF elevados indican colinealidad entre predictores, NO fallas de sensores

Diagnóstico VIF



VIF: CDP y GTEP presentan VIF > 100 por colinealidad extrema (r = 0,99)

4. La evaluación representa el uso futuro

INGENIERÍA INDUSTRIAL
UNIVERSIDAD DE SANTIAGO DE CHILE

Partición cronológica



Folds

- Fold 1: entrenar 2011 → validar 2012.
- Fold 2: entrenar 2011–2012 → validar 2013.
- Fold 3: entrenar 2011–2013 → validar el inicio de 2014.
- Prueba final: año 2015, sin utilizar durante la selección del modelo.

Cortes y protección

- Desarrollo y selección: 2011–2014.
- Test 2015: 7.384 registros.
- Tramo final de 2014: 1.790 registros para calibrar incertidumbre.
- Mismos cortes temporales para comparar modelos.
- Escalado y ajustes calculados solo con cada entrenamiento.
- Semilla 2026 para reproducibilidad

5. Modelos de Regresión Comparados

Lineal y regularización

•Baseline: predicción de la media histórica; referencia mínima.

• OLS: mínimos cuadrados; interpretable, pero sensible a multicolinealidad.

• Ridge (L2, $\alpha = 0$): reduce magnitud de coeficientes.

• Lasso (L1, $\alpha = 1$): puede anular coeficientes.

• Elastic Net ($0 < \alpha < 1$): combina L1 y L2

Flexibles y ensembles

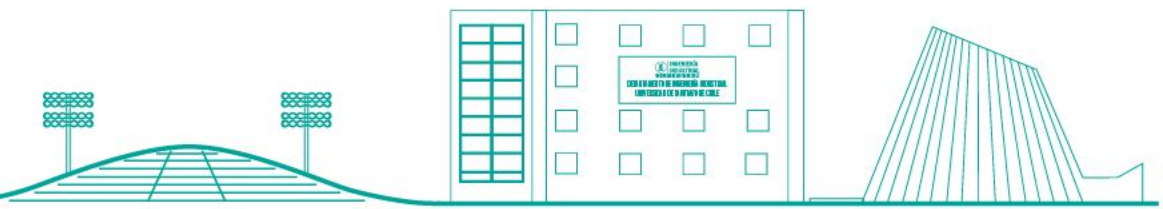
• GAM: relaciones suaves, potencialmente no lineales.

• Árbol de regresión: reglas y segmentación.

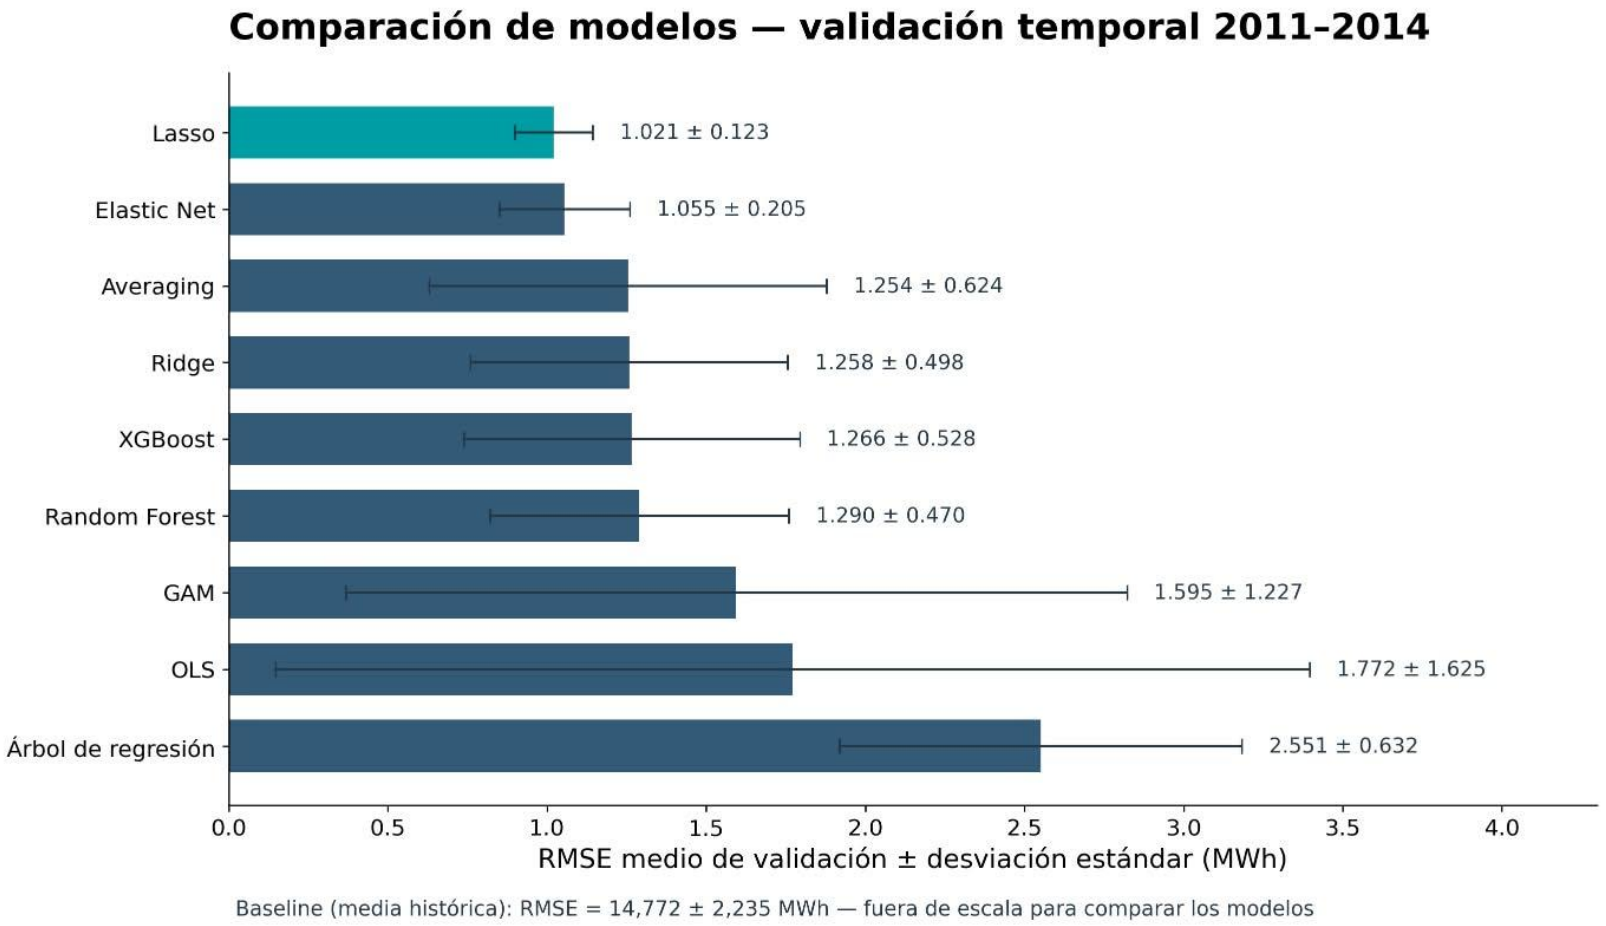
• Random Forest: ensamble de árboles con aleatorización.

• XGBoost: árboles construidos mediante boosting.

• Averaging: promedio de predicciones de varios modelos



6. Comparación y Estabilidad entre Modelos



- Cada barra muestra el RMSE medio de los folds

(menor = mejor).

- Las líneas negras representan ± 1 desviación

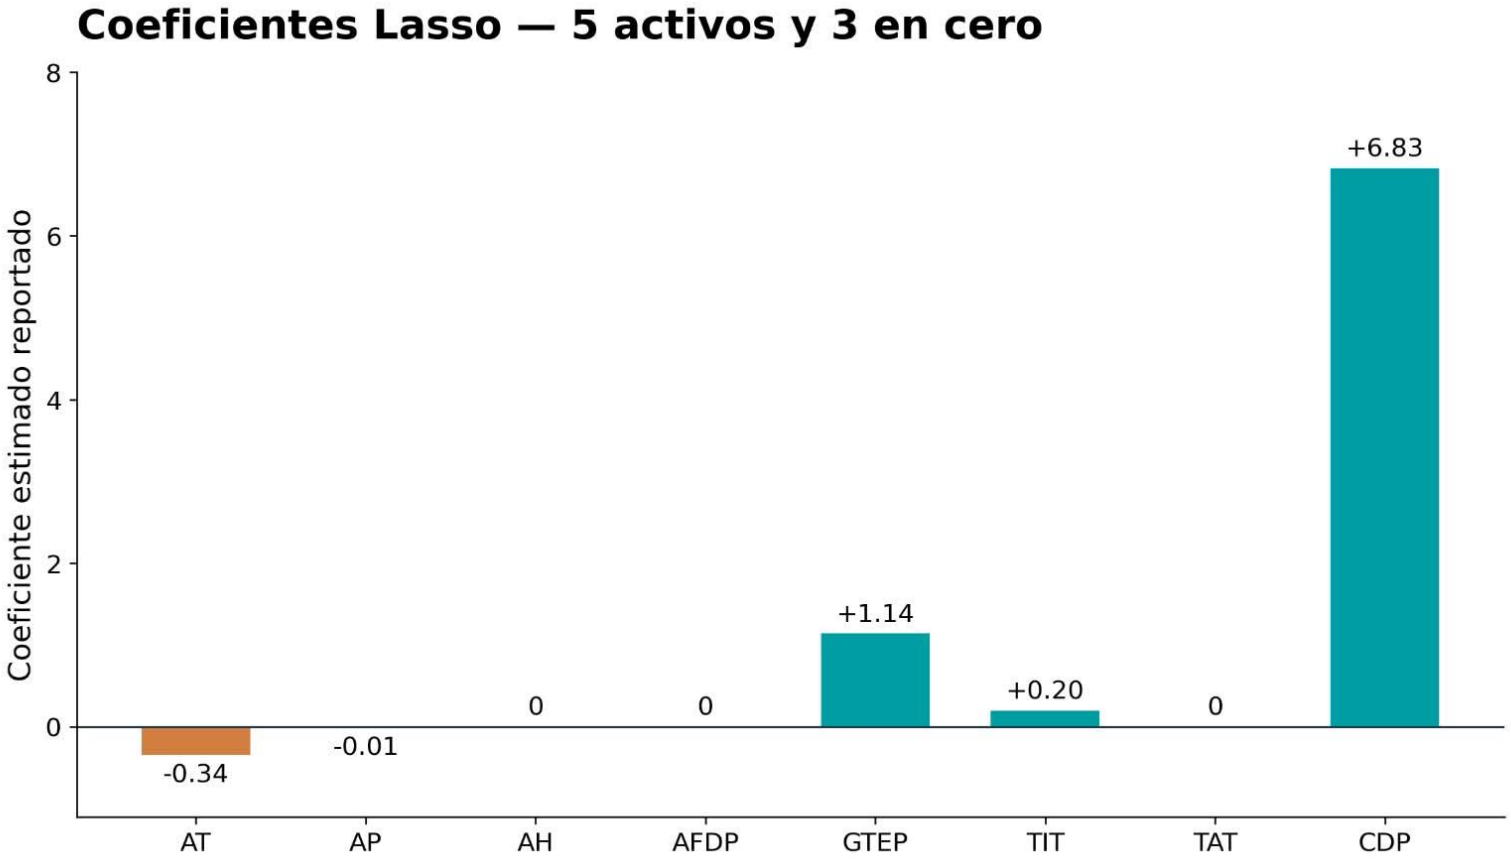
estándar entre folds, no un IC95%.

- Lasso: 1,021 ± 0,123.
- Elastic Net: 1,055 ± 0,205.
- Baseline: 14,772 ± 2,235; fuera de escala.
- Lasso también reporta MAE = 0,813.
- Se selecciona Lasso ANTES de evaluar 2015.

7. Interpretación Modelo Lasso

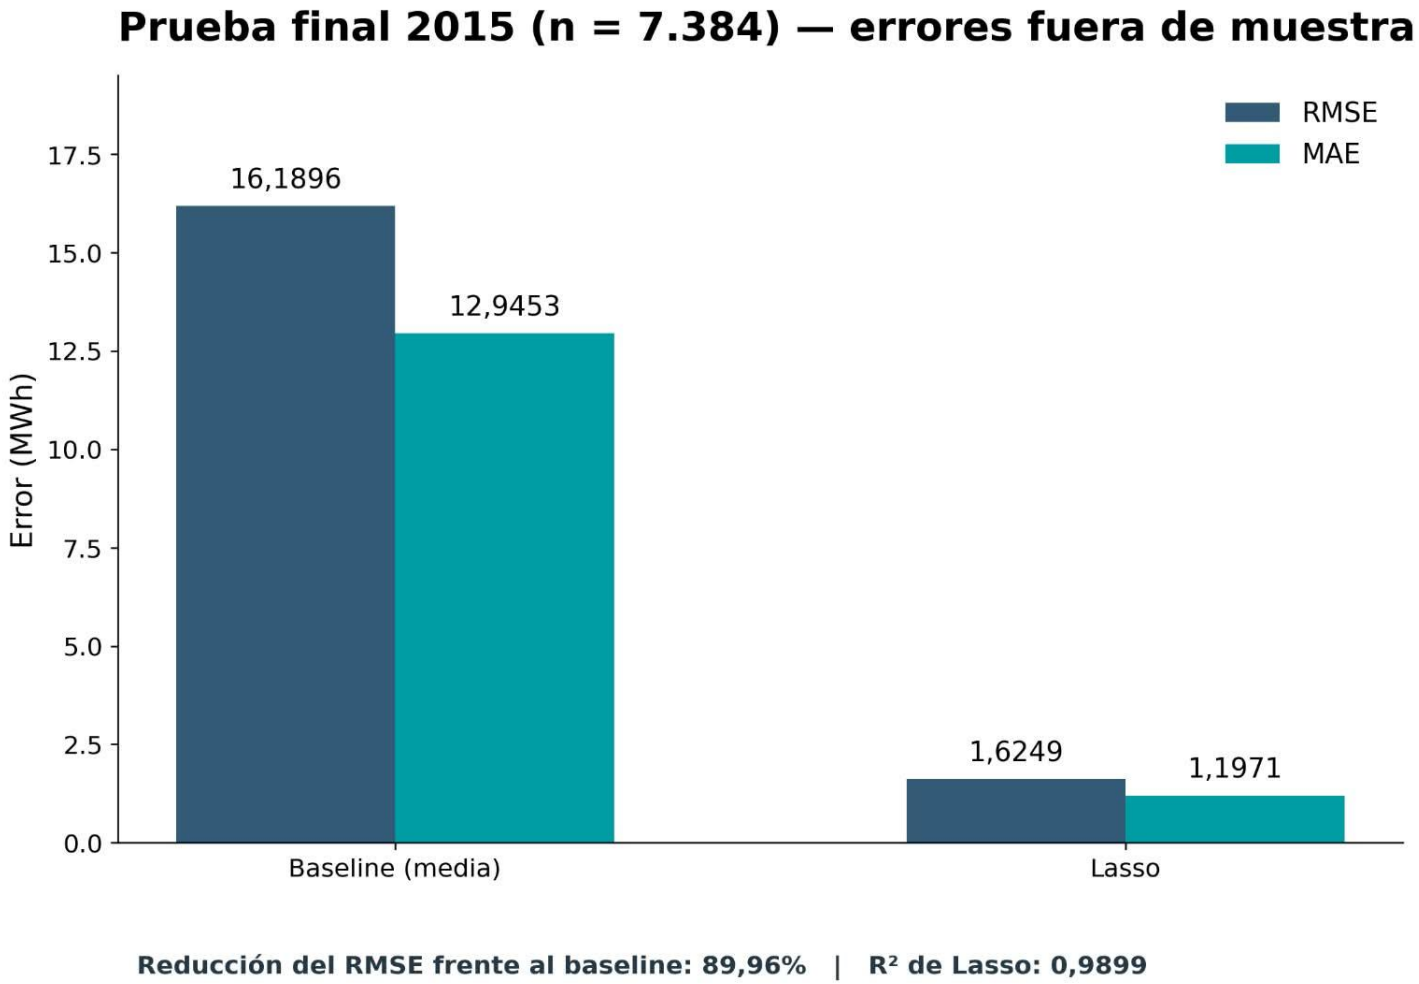
Efectos parciales

- Cinco variables activas: AT, AP, GTEP, TIT y CDP.
- En cero: AH, AFDP y TAT (selección por penalización L1).
- AT y AP: signo negativo; GTEP, TIT y CDP: positivo.
- CDP = +6,83 es el mayor coeficiente numérico reportado.
- Las magnitudes dependen de unidades y escalas; no prueban causalidad.
- Un coeficiente cero no implica que el sensor carezca de valor físico.



No comparar magnitudes sin comprobar escalas/unidades; asociación predictiva, no efecto causal.

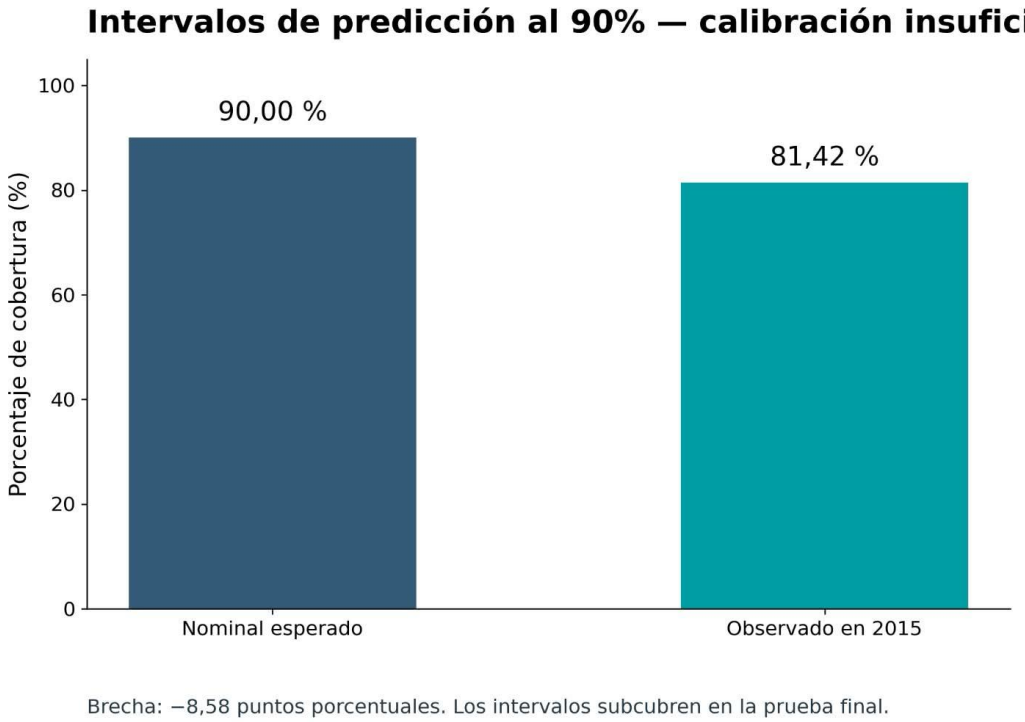
8. El test evalúa un sistema congelado



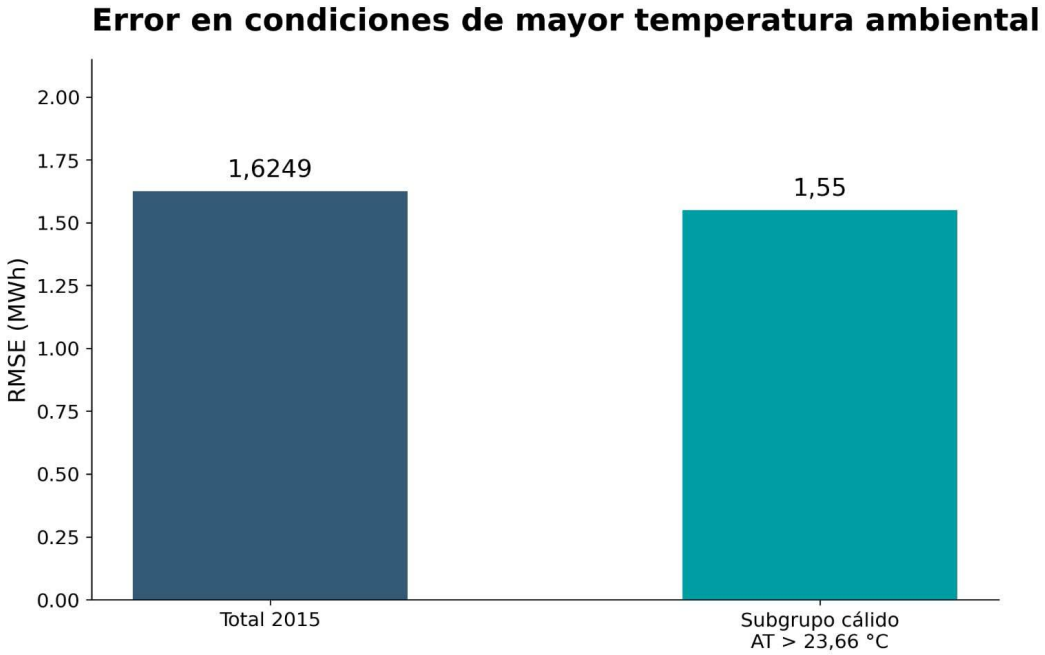
Resultados fuera de muestra

- Test: 7.384 horas (2015).
- Lasso: RMSE 1,6249; MAE 1,1971 MWh.
- Baseline: RMSE 16,1896; MAE 12,9453 MWh.
- R^2 Lasso = 0,9899.
- Mejora de RMSE: 89,96%.
- El 89,96%de mejora en RMSE reduce errores técnicos de estimación, pero su traducción a ahorros financieros requiere un modelo económico adicional de la planta.

9. Intervalos de predicción y subgrupos



Brecha: −8,58 puntos porcentuales. Los intervalos subcubren en la prueba final.



El tamaño n del subgrupo no figura en el informe; esta comparación no demuestra mayor robustez por sí sola.

- Intervalo predictivo nominal: 90%; cobertura observada: 81,42%.
- Brecha de −8,58 puntos porcentuales: subcobertura.
- Los intervalos deben recalibrarse antes de un uso crítico

- Para AT > 23,66 °C: RMSE = 1,55 vs. 1,6249 del test completo.
- n = 2.748 reportado: equivale al 37,2% de 7.384 (NO al 25%).
- Verificar n con el CSV de subgrupos y revisar residuos.

10. Recomendación y monitoreo

Recomendación

- Usar Lasso como estimador contemporáneo de referencia.
- Comparar TEY medida frente a TEY estimada en cada hora.
- Revisar desviaciones persistentes y verificar sensores/operación.
- No extrapolar a otras turbinas ni usarlo como pronóstico comercial sin revalidación.

Control de desempeño

- Registrar error horario, MAE, RMSE y cobertura predictiva.
- Monitorear cambios en sensores y distribución de X (drift).
- Recalibrar con bloques temporales recientes.
- Alerta de |error| > 3 MWh: umbral preliminar, aún sin validación.
- No se cuantifican consumo de gas ni ahorros monetarios.

PREGUNTAS Y DEFENSA TÉCNICA

INGENIERÍA INDUSTRIAL

UNIVERSIDAD DE SANTIAGO DE CHILE